

# Support Vector Machine

## SVM

Dr. Mauricio Toledo-Acosta

Diplomado Ciencia de Datos con Python

# Table of Contents

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- 1 Introducción
- 2 SVM de margen duro
- 3 SVM de margen suave
- 4 Kernel Trick
- 5 Métricas de desempeño

# Introducción

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

# Introducción

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño


## Support Vector Machine

Modelo supervisado de clasificación binaria que busca encontrar una frontera de decisión óptima que separe las clases de puntos.



## El modelo lineal de clasificación

Los puntos  $x$  que satisfacen  $y(x) = w^T \cdot x + w_0 = 0$  forman la frontera de decisión (FD), la cual divide al espacio de datos en dos regiones.



# Table of Contents

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- 1 Introducción
- 2 SVM de margen duro
- 3 SVM de margen suave
- 4 Kernel Trick
- 5 Métricas de desempeño

# SVM de margen duro

Support  
Vector  
Machine

Clasificación

Introducción


SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

Analicemos el caso con datos linealmente separables. Cambiaremos ligeramente la notación, FD está definida por  $g(x) = w^T \cdot x - t = 0$ . Queremos encontrar una FD con margen  $m = 1$ .





# Planteamiento del problema

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick


Métricas de  
desempeño

► Nuestro objetivo es:

$$\mathbf{w}^*, t^* = \operatorname{argmin}_{\mathbf{w}, t} \frac{1}{2} \|\mathbf{w}\|^2$$

► Sujeto a las siguientes  $N$  restricciones:

$$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle - t) \geq 1, \quad 1 \leq i \leq N$$



# Planteamiento del problema

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

► Definimos el lagrangiano

$$\begin{aligned}\mathcal{L}_P(\mathbf{w}, t, \alpha_1, \dots, \alpha_N) &= \overset{\text{Minimizar}}{\downarrow} \frac{1}{2} \|\mathbf{w}\|^2 - \overset{\text{Maximizar}}{\downarrow} \sum_{i=1}^N \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - t) - 1) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i y_i \langle \mathbf{w}, \mathbf{x}_i \rangle + \sum_{i=1}^N \alpha_i y_i t + \sum_{i=1}^N \alpha_i \\ &= \frac{1}{2} \langle \mathbf{w}, \mathbf{w} \rangle - \langle \mathbf{w}, \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \rangle + t \left( \sum_{i=1}^N \alpha_i y_i \right) + \sum_{i=1}^N \alpha_i\end{aligned}$$

► Para un  $t$  óptimo  $\partial_t \mathcal{L}_P = 0 \Rightarrow \sum_{i=1}^N \alpha_i y_i = 0$

► Para pesos óptimos  $\partial_{\mathbf{w}} \mathcal{L}_P = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$

# Planteamiento del problema

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- Reinsertando estas expresiones en  $\mathcal{L}_P$  obtenemos  $\mathcal{L}_D$  el lagrangiano del problema dual:

$$\mathcal{L}_D(\alpha_1, \dots, \alpha_N) = -\frac{1}{2} \left\langle \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i, \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \right\rangle + \sum_{i=1}^N \alpha_i$$

$$= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \sum_{i=1}^N \alpha_i$$

# Planteamiento del problema

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- *El problema de optimización dual es el siguiente:*

$$\alpha_1^*, \dots, \alpha_N^* = \operatorname{argmax}_{\alpha_1, \dots, \alpha_N} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \sum_{i=1}^N \alpha_i$$

- *Sujeto a las restricciones:*

$$\alpha_i > 0, \quad 1 \leq i \leq N \quad \text{y} \quad \sum_{i=1}^N \alpha_i y_i = 0$$

# Ejemplo

Support  
Vector  
Machine

Clasificación

Introducción


SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- Encuentra  $W$  óptimo para este problema:  $X_1=[0,0]$   $X_2=[1,0]$  para la clase (+1) y  $X_3=[2,0]$  y  $X_4=[0,2]$  para la clase (-1)



# Ejemplo

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

$$\mathcal{L}_D(\alpha_1, \dots, \alpha_N) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

$$\mathcal{L}_D = (\alpha_1 + \alpha_2 + \alpha_3 + \alpha_4) - \frac{1}{2} (\alpha_2^2 - 4\alpha_2\alpha_3 + 4\alpha_3^2 + 4\alpha_4^2)$$

Diferenciando con respecto a los  $\alpha$ 's y utilizando la restricción  $\sum_{i=1}^N \alpha_i y_i = 0$  obtenemos:

$$\begin{cases} \alpha_1 + \alpha_2 - \alpha_3 - \alpha_4 = 0 \\ \alpha_2 - 2\alpha_3 = 1 \\ -2\alpha_2 + 4\alpha_3 = 1 \\ 4\alpha_4 = 1 \end{cases}$$

de donde:  $\alpha_1 = 0$ ,  $\alpha_2 = 1$ ,  $\alpha_3 = \frac{3}{4}$ ,  $\alpha_4 = 1/4$

Aplicando:  $\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$ , finalmente obtenemos

$$\mathbf{w} = \begin{bmatrix} -1/2 \\ -1/2 \end{bmatrix}, w_0 = 3/4 \text{ y } d(x) = 3 - 2x_1 - 2x_2 = 0$$

# Table of Contents

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- 1 Introducción
- 2 SVM de margen duro
- 3 SVM de margen suave
- 4 Kernel Trick
- 5 Métricas de desempeño





# SVM de margen suave

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

$$\mathbf{w}^*, t^*, \xi_i^* = \underset{\mathbf{w}, t, \xi_i}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

sujeto a  $y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle - t) \geq 1 - \xi_i$  y  $\xi_i \geq 0, 1 \leq i \leq N$

- $C$  es un parámetro definido por el usuario que balancea la maximización del margen contra la minimización de las variables de holgura:
  - un valor alto de  $C$  significa que los errores de margen son altamente costosos,
  - un valor pequeño de  $C$  permite más errores de margen con tal de hacer mas grande el margen.
- Si permitimos más errores de margen necesitamos menos vectores de soporte, por lo tanto  $C$  controla la 'complejidad' de la SVM y por ello se le denomina el *parámetro de complejidad*.

# SVM de margen suave

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- Buscamos soluciones mediante el nuevo Lagrangiano:

$$\begin{aligned}\mathcal{L}(\mathbf{w}, t, \xi_i, \alpha_i, \beta_i) &= \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle - t) - (1 - \xi_i)) - \sum_{i=1}^N \beta_i \xi_i \\ &= \mathcal{L}(\mathbf{w}, t, \alpha_i) + \sum_{i=1}^N (C - \alpha_i - \beta_i) \xi_i\end{aligned}$$

- La solución óptima es tal que  $\partial_{\xi_i} \mathcal{L} = 0 \Rightarrow$  el término añadido desaparece en el problema dual.
- Además, puesto que  $\alpha_i$  y  $\beta_i$  son positivos,  $\alpha_i$  no puede ser mayor a  $C$ :

$$\alpha_1^*, \dots, \alpha_N^* = \operatorname{argmax}_{\alpha_1, \dots, \alpha_N} -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle + \sum_{i=1}^N \alpha_i$$

Sujeto a las restricciones:  $0 \leq \alpha_i \leq C$ ,  $1 \leq i \leq N$       y       $\sum_{i=1}^N \alpha_i y_i = 0$

# Table of Contents

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- 1 Introducción
- 2 SVM de margen duro
- 3 SVM de margen suave
- 4 Kernel Trick**
- 5 Métricas de desempeño

# El truco del Kernel

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño



# El truco del Kernel

Support  
Vector  
Machine

Clasificación


Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño



# Tipos de Kernel

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- Aunque nuevos kernels aparecen en la literatura, los siguientes cuatro son básicos y ampliamente utilizados:

**Lineal:**

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \langle \mathbf{x}_i, \mathbf{x}_j \rangle$$

**Polinomial:**

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\langle \mathbf{x}_i, \mathbf{x}_j \rangle + r)^p, r \geq 0$$

**Gaussiano (*Radial Basis Function* – RBF):**

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(\frac{-\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right) = \exp\left(-\gamma\|\mathbf{x}_i - \mathbf{x}_j\|^2\right)$$

**Sigmoide:**

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\gamma\langle \mathbf{x}_i, \mathbf{x}_j \rangle + r)$$

donde  $r, p, \gamma$  son parámetros de los modelos.

# Table of Contents

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- 1 Introducción
- 2 SVM de margen duro
- 3 SVM de margen suave
- 4 Kernel Trick
- 5 Métricas de desempeño

# Matriz de Confusión

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

		Predicted condition	
		Positive (PP)	Negative (PN)
Actual condition	Total population = P + N		
	Positive (P)	True positive (TP)	False negative (FN)
	Negative (N)	False positive (FP)	True negative (TN)



# Métricas de desempeño

Support  
Vector  
Machine

Clasificación

Introducción

SVM de  
margen duro

SVM de  
margen suave

Kernel Trick

Métricas de  
desempeño

- **Accuracy:** De todos la población, ¿cuántos predije correctamente?

$$A = \frac{TP + TN}{\text{Total}}.$$

- **Recall:** De todos la población positiva, ¿cuántos predije correctamente como positivos?

$$R = \frac{TP}{TP + FN}.$$

- **Precision:** De todos los que predije como positivos, ¿cuántos son realmente positivos?

$$P = \frac{TP}{TP + FP}.$$

- **F1 score:** Media armónica de la precisión y el recall:

$$2 \frac{P \cdot R}{P + R}$$

# Ejemplo

Tenemos la siguiente población  $\{+ + - - - -\}$ :

- El clasificador predice todo como  $-$ :

real	+	+	-	-	-	-
predicho	-	-	-	-	-	-

Accuracy: 0.66, Recall: 0, Precision: 0.

- El clasificador predice todo como  $+$ :

real	+	+	-	-	-	-
predicho	+	+	+	+	+	+

Accuracy: 0.33, Recall: 1, Precision: 0.33.